Math-Net.Ru
Общероссийский математический портал

А. Я. Хинчин, Понятие энтропии в теории вероятностей, *УМН*, 1953, том 8, выпуск 3, 3–20

Использование Общероссийского математического портала Math-Net.Ru подразумевает, что вы прочитали и согласны с пользовательским соглашением
http://www.mathnet.ru/rus/agreement

Параметры загрузки:
IP: 74.101.44.67
30 октября 2024 г., 09:07:09

1953 г. май—июнь *т. VIII, вып. 3 (55)*

УСПЕХИ МАТЕМАТИЧЕСКИХ НАУК

ПОНЯТИЕ ЭНТРОПИИ В ТЕОРИИ ВЕРОЯТНОСТЕЙ

А. Я. Хинчин

Общая схема взаимной связи научной теории с практикой, даваемая диалектико-материалистической теорией познания, для математической науки превосходно выражена хорошо известными словами П. Л. Чебышева (в его статье «О черчении географических карт»): «сближение теории с практикой даёт самые благоприятные результаты, и не одна только практика от этого выигрывает: сами науки развиваются под влиянием её; она открывает им новые предметы для исследования или новые стороны в предметах давно известных».

Убедительный пример явления, описанного Чебышевым, даёт нам выросшее за самые последние годы из нужд практики понятие энтропии в теории вероятностей. Это понятие возникло впервые при попытках создать теоретическое обоснование для передачи информации различного рода; оно вводилось первоначально в тесной связи с передающими установками того или другого определённого типа. Лишь постепенно было осознано его общетеоретическое значение, установлены его общие свойства и общие схемы его практических приложений. Однако и до сих пор сколько-нибудь цельное изложение теории энтропии можно найти только в специальных статьях и монографиях, посвящённых вопросам передачи информации; хотя учение об энтропии фактически выросло уже в важную и содержательную главу общей теории вероятностей, изложение его в этом общетеоретическом плане до сих пор отсутствует.

Настоящая статья представляет собой первый опыт такого изложения. При составлении её я опирался главным образом на работу Шеннона «Математическая теория сообщений» [1]. Однако изложение Шеннона не всегда в достаточной степени полно и математически корректно, так что помимо естественной необходимости освободить теорию от практических деталей мне пришлось во многом дополнять и изменять как формулировки определений и теорем, так и доказательства последних.

Можно не сомневаться, что учение об энтропии в ближайшие годы должно стать неотъемлемой главой теории вероятностей; поэтому проделанная мной работа представляется мне необходимым этапом в развитии этого учения.

1. ЭНТРОПИЯ КОНЕЧНЫХ СХЕМ

Полной системой событий $A_1, A_2, \ldots, A_n$ в теории вероятностей называют такую группу событий, что в каждом испытании обязательно наступает одно и только одно из них (выпадение 1, 2, 3, 4, 5 или 6 при бросании игральной кости). В случае $n=2$ мы имеем простую альтернативу (пару противоположных событий: выпадение герба или надписи при бросании монеты). Если события $A_1, A_2, \ldots, A_n$ некоторой полной системы заданы вместе с их вероятностями $p_1, p_2, \ldots, p_n$ $\left(p_i \geqslant 0, \sum_{i=1}^{n} p_i = 1\right)$, то мы условимся говорить, что нам задана конечная схема

$$A = \begin{pmatrix} A_1 & A_2 & \ldots & A_n \\ p_1 & p_2 & \ldots & p_n \end{pmatrix}. \tag{1}$$

В случае «правильной» игральной кости, обозначая через A_i $(1 \leqslant i \leqslant 6)$ выпадение i очков, мы имеем конечную схему

$$\begin{pmatrix} A_1 & A_2 & A_3 & A_4 & A_5 & A_6 \\ \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & \frac{1}{6} \end{pmatrix}.$$

Всякая конечная схема описывает нам некоторое состояние неопределённости: мы стоим перед испытанием, исходом которого должно быть одно из событий $A_1, A_2, \ldots, A_n$; нам известны лишь вероятности этих возможных исходов. Нам представляется очевидным, что степень этой неопределённости различна в различных схемах; так, из двух простых альтернатив

$$\begin{pmatrix} A_1 & A_2 \\ 0{,}5 & 0{,}5 \end{pmatrix}, \qquad \begin{pmatrix} A_1 & A_2 \\ 0{,}99 & 0{,}01 \end{pmatrix}$$

первая, очевидно, несёт с собой значительно бóльшую неопределённость, чем вторая: во второй результатом испытания «почти наверняка» будет A_1, в первой же мы естественно воздержимся от всяких прогнозов. Схема

$$\begin{pmatrix} A_1 & A_2 \\ 0{,}3 & 0{,}7 \end{pmatrix}$$

по степени неопределённости занимает положение, промежуточное между двумя предыдущими, и т. д.

Для ряда приложений представляется желательным введение такой величины, которая разумным образом измеряла бы собой степень неопределённости, создаваемой любой данной конечной схемой. Мы убедимся, что весьма удобной мерой неопределённости конечной схемы (1) может служить величина

$$H(p_1, p_2, \ldots, p_n) = -\sum_{k=1}^{n} p_k \lg p_k,$$

где логарифмы берутся при произвольном, но во всех случаях одном и том же основании, и где при $p_k = 0$ всегда принимается $p_k \lg p_k = 0$. Величину $H(p_1, p_2, \ldots, p_n)$ мы будем, следуя некоторым физическим аналогиям (на которых здесь нет надобности останавливаться), называть энтропией конечной схемы (1). Убедимся теперь, что эта функ-

ция действительно обладает рядом свойств, которых мы склонны требовать от разумно заданной меры неопределённости конечной схемы.

Прежде всего мы видим непосредственно, что $H(p_1, p_2, \ldots, p_n) = 0$ в том и только в том случае, когда из чисел $p_1, p_2, \ldots, p_n$ какое-нибудь одно равно единице (а все остальные — нули). Но это как раз случай, когда результат испытания может быть предсказан заранее с полной достоверностью и когда, следовательно, отсутствует какая бы то ни было неопределённость. Во всех других случаях энтропия положительна.

Далее, при фиксированном n нам представляется очевидным, что наибольшей неопределённостью обладает схема, в которой все исходы одинаково вероятны, т. е. $p_k = \frac{1}{n}$ $(k = 1, 2, \ldots, n)$. И действительно, энтропия получает своё наибольшее значение именно при этих значениях переменных p_k. Проще всего в этом убедиться, опираясь на имеющее место для всех непрерывных выпуклых функций $\varphi(x)$ неравенство

$$\varphi\left(\frac{1}{n}\sum_{k=1}^{n} a_k\right) \leqslant \frac{1}{n}\sum_{k=1}^{n} \varphi(a_k),$$

где $a_1, a_2, \ldots, a_n$ — любые положительные числа; полагая $a_k = p_k$ и $\varphi(x) = x \lg x$, мы находим (учитывая, что $\sum_{k=1}^{n} p_k = 1$):

$$\varphi\left(\frac{1}{n}\right) = \frac{1}{n}\lg\frac{1}{n} \leqslant \frac{1}{n}\sum_{k=1}^{n} p_k \lg p_k = -\frac{1}{n} H(p_1, p_2, \ldots, p_n),$$

откуда

$$H(p_1, p_2, \ldots, p_n) \leqslant \lg n = H\left(\frac{1}{n}, \frac{1}{n}, \ldots, \frac{1}{n}\right),$$

что и надо было доказать.

Пусть мы теперь имеем две конечные схемы:

$$A = \begin{pmatrix} A_1 & A_2 & \ldots & A_n \\ p_1 & p_2 & \ldots & p_n \end{pmatrix}, \qquad B = \begin{pmatrix} B_1 & B_2 & \ldots & B_m \\ q_1 & q_2 & \ldots & q_m \end{pmatrix}$$

и пусть эти схемы *взаимно независимы*, т. е. вероятность π_{kl} совместного наступления событий A_k и B_l равна $p_k q_l$. Совокупность событий $A_k B_l$ $(1 \leqslant k \leqslant n,\ 1 \leqslant l \leqslant m)$ с вероятностями π_{kl} образует тогда новую конечную схему, которую мы будем называть о б ъ е д и н е н и е м схем A и B и обозначать через AB. Пусть $H(A)$, $H(B)$, $H(AB)$ означают соответственно энтропии схем A, B и AB. Тогда

$$H(AB) = H(A) + H(B). \tag{2}$$

В самом деле,

$$-H(AB) = \sum_k \sum_l \pi_{kl} \lg \pi_{kl} = \sum_k \sum_l p_k q_l (\lg p_k + \lg q_l) =$$
$$= \sum_k p_k \lg p_k \sum_l q_l + \sum_l q_l \lg q_l \sum_k p_k = -H(A) - H(B).$$

Обратимся теперь к случаю, когда схемы A и B взаимно зависимы. Обозначим через q_{kl} вероятность того, что в схеме B наступит событие B_l

при условии, что в схеме A наступило событие A_k, так что

$$\pi_{kl} = p_k q_{kl} \qquad (1 \leqslant k \leqslant n,\ 1 \leqslant l \leqslant m).$$

Тогда

$$-H(AB) = \sum_k \sum_l p_k q_{kl} (\lg p_k + \lg q_{kl}) =$$
$$= \sum_k p_k \lg p_k \sum_l q_{kl} + \sum_k p_k \sum_l q_{kl} \lg q_{kl}.$$

Здесь $\sum_l q_{kl} = 1$ при любом k, а сумма $-\sum_l q_{kl} \lg q_{kl}$ может рассматриваться как условная энтропия $H_k(B)$ схемы B, вычисленная при условии, что в схеме A наступило событие A_k. Мы получаем:

$$H(AB) = H(A) + \sum_k p_k H_k(B).$$

Условная энтропия $H_k(B)$ есть, очевидно, случайная величина в схеме A: значение её полностью определяется тем, какое событие A_k схемы A окажется наступившим. Поэтому последний член правой части представляет собой *математическое ожидание величины $H(B)$ в схеме A*, которое мы будем обозначать через $H_A(B)$. Таким образом, в самом общем случае мы имеем:

$$H(AB) = H(A) + H_A(B). \tag{3}$$

Само собой разумеется, что в частном случае, когда схемы A и B взаимно независимы, соотношение (3) обращается в (2).

Интересно ещё заметить, что во всех случаях $H_A(B) \leqslant H(B)$; это неравенство можно разумным образом истолковать так, что знание исхода схемы A может в среднем лишь уменьшить неопределённость схемы B. Для доказательства заметим, что любая непрерывная выпуклая функция $f(x)$ удовлетворяет тождественному неравенству[1])

$$\sum_k \lambda_k f(x_k) \geqslant f\left(\sum_k \lambda_k x_k\right),$$

если $\lambda_k \geqslant 0$, $\sum_k \lambda_k = 1$. Полагая $f(x) = x \lg x$, $\lambda_k = p_k$, $x_k = q_{kl}$, мы находим поэтому при любом l

$$\sum_k p_k q_{kl} \lg q_{kl} \geqslant \left(\sum_k p_k q_{kl}\right) \lg \left(\sum_k p_k q_{kl}\right) = q_l \lg q_l,$$

так как, очевидно, $\sum_k p_k q_{kl} = q_l$. Суммируя по l, мы в левой части получаем величину

$$\sum_k p_k \sum_l q_{kl} \lg q_{kl} = -\sum_k p_k H_k(B) = -H_A(B)$$

и, следовательно, находим:

$$-H_A(B) \geqslant \sum_l q_l \lg q_l = -H(B),$$

что и надо было доказать.

Если мы реализуем то испытание, возможные исходы которого описываются данной схемой A, то мы получаем тем самым некоторую *инфор-*

---

[1]) См., например, Харди, Литтльвуд и Полиа, Неравенства, ГИИЛ, 1948, стр. 93.

мацию (узнаём, какое из событий A_k действительно наступило), и неопределённость данной схемы полностью ликвидируется. Можно, таким образом, сказать, что информация, которую даёт нам реализация какого-либо испытания, состоит в снятии той неопределённости, которая предшествовала этому испытанию. Чем больше была эта неопределённость, тем выше мы должны оценивать информацию, полученную нами в результате её ликвидации. А так как неопределённость конечной схемы A мы условились измерять её энтропией $H(A)$, то количество информации, даваемое ликвидацией этой неопределённости, естественно считать возрастающей функцией величины $H(A)$. Выбор этой функции означает выбор той или иной шкалы для количества информации и с принципиальной точки зрения может поэтому считаться безразличным. Однако доказанные нами выше свойства энтропии показывают, что чрезвычайно удобно считать это количество информации просто пропорциональным энтропии. В самом деле, рассмотрим две конечные схемы A и B и их объединение AB. Реализация схемы AB, очевидно, равносильна реализации обеих схем A и B; если поэтому схемы A и B взаимно независимы, то нам представляется естественным считать, что информация, даваемая реализацией схемы AB, равна сумме тех двух количеств информации, которые даются реализацией схем A и B, а так как в этом случае

$$H(AB) = H(A) + H(B),$$

то наше требование действительно будет выполнено, если мы условимся считать количество информации, даваемой реализацией какой-либо конечной схемы, пропорциональным энтропии этой схемы. Множитель пропорциональности можно принять, конечно, равным единице, так как такой выбор равносилен просто выбору единицы измерения. Итак, мы можем во всём дальнейшем считать количество информации, даваемое реализацией какой-либо конечной схемы, равным энтропии этой схемы. Это соглашение придаёт понятию энтропии особенно большое значение для теории информации.

Рассмотрим ещё в свете этого соглашения случай двух взаимно зависимых схем A и B и соответствующее соотношение (3). Количество информации, даваемое реализацией схемы AB, равно $H(AB)$. Однако в общем случае, как это заранее ясно, оно не может быть равно $H(A) + H(B)$. В самом деле, представим себе, например, тот крайний случай, когда знание исхода схемы A с достоверностью предрешает и исход схемы B, так что каждое событие A_k схемы A может сочетаться только с одним определённым событием B_l схемы B. Тогда после реализации схемы A схема B полностью теряет свою неопределённость, и мы имеем $H_A(B) = 0$; вместе с тем в этом случае, очевидно, реализация схемы B не даёт уже никакой дополнительной информации, и мы имеем $H(AB) = H(A)$, так что соотношение (3) действительно оказывается выполненным. Во всех случаях введённая нами выше величина $H_k(B)$ означает количество дополнительной информации, даваемой схемой B, при условии, что в схеме A имело место событие A_k; поэтому величина $H_A(B) = \sum_k p_k H_k(B)$ означает математическое ожидание количества дополнительной информации, даваемой реа-

лизацией схемы B, после того как схема A уже реализована и соответствующая информация получена. Соотношение (3) получает поэтому следующую вполне разумную интерпретацию: *количество информации, которую нам даёт реализация двух конечных схем A и B, равно количеству информации, даваемому реализацией схемы A, сложенному с математическим ожиданием количества дополнительной информации, даваемой реализацией схемы B, при условии, что схема A уже реализована.*

Точно так же вполне разумную интерпретацию получает и доказанное нами общее неравенство $H_A(B) \leqslant H(B)$: *количество информации, даваемой реализацией любой схемы B, может только уменьшиться, если мы предварительно реализуем какую-нибудь другую схему A.*

2. ТЕОРЕМА ЕДИНСТВЕННОСТИ

Среди доказанных нами свойств понятия энтропии мы можем считать основными два следующих:

1°. Функция $H(p_1, p_2, \ldots, p_n)$ при данном n и при $\sum_{k=1}^{n} p_k = 1$ получает наибольшее значение, если $p_k = \frac{1}{n}$ $(k = 1, 2, \ldots, n)$.

2°. $H(AB) = H(A) + H_A(B)$.

Мы присоединим к этим двум свойствам ещё третье, которое очевидным образом должно выполняться при любом разумном определении энтропии. Так как схемы

$$\begin{pmatrix} A_1 & A_2 & \ldots & A_n \\ p_1 & p_2 & \ldots & p_n \end{pmatrix} \quad \text{и} \quad \begin{pmatrix} A_1 & A_2 & \ldots & A_n & A_{n+1} \\ p_1 & p_2 & \ldots & p_n & 0 \end{pmatrix},$$

очевидно, реально ничем не отличаются друг от друга, то мы должны иметь

3°. $H(p_1, p_2, \ldots, p_n, 0) = H(p_1, p_2, \ldots, p_n)$

(добавление к данной схеме одного невозможного события, а значит, и любого числа таких событий не изменяет её энтропии).

Докажем теперь следующее важное предложение.

Теорема 1. *Пусть $H(p_1, p_2, \ldots, p_n)$ есть функция, определённая для любого натурального числа n и для всех значений $p_1, p_2, \ldots, p_n$ таких, что $p_k \geqslant 0$ $(k = 1, 2, \ldots, n)$, $\sum_{k=1}^{n} p_k = 1$. Если эта функция при любом n непрерывна относительно совокупности своих аргументов и если она обладает свойствами 1°, 2° и 3°, то*

$$H(p_1, p_2, \ldots, p_n) = -\lambda \sum_{k=1}^{n} p_k \lg p_k,$$

где λ — постоянное положительное число.

Эта теорема показывает, что выбранное нами выражение энтропии конечной схемы является единственно возможным, если мы хотим, чтобы оно обладало некоторыми общими свойствами, которые представляются нам необходимыми в свете реального значения понятия энтропии (как меры неопределённости или как количества информации).

Доказательство. Положим для краткости

$$H\left(\frac{1}{n}, \frac{1}{n}, \ldots, \frac{1}{n}\right) = L(n)$$

и докажем, что $L(n) = \lambda \lg n$, где λ — положительная постоянная. В силу 3° и 1° мы имеем:

$$L(n) = H\left(\frac{1}{n}, \frac{1}{n}, \ldots, \frac{1}{n}, 0\right) \leqslant H\left(\frac{1}{n+1}, \frac{1}{n+1}, \ldots, \frac{1}{n+1}\right) = L(n+1),$$

так что $L(n)$ есть неубывающая функция от n.

Пусть m и r — натуральные числа. Рассмотрим m взаимно независимых конечных схем $S_1, S_2, \ldots, S_m$, каждая из которых содержит r одинаково вероятных событий, так что

$$H(S_k) = H\left(\frac{1}{r}, \frac{1}{r}, \ldots, \frac{1}{r}\right) = L(r) \qquad (1 \leqslant k \leqslant m).$$

В силу свойства 2° (обобщённого на случай m схем) мы имеем ввиду взаимной независимости схем S_k

$$H(S_1 S_2 \ldots S_m) = \sum_{k=1}^{m} H(S_k) = mL(r).$$

Но объединённая схема $S_1 S_2 \ldots S_m$ состоит, очевидно, из r^m равновероятных между собой событий, так что энтропия её равна $L(r^m)$. Поэтому мы находим:

$$L(r^m) = mL(r) \tag{4}$$

и аналогично для любой другой пары натуральных чисел n, s:

$$L(s^n) = nL(s). \tag{5}$$

Пусть теперь числа r, s и n заданы произвольно, а число m определяется неравенствами

$$r^m \leqslant s^n < r^{m+1}, \tag{6}$$

откуда

$$m \lg r \leqslant n \lg s < (m+1) \lg r,$$

$$\frac{m}{n} \leqslant \frac{\lg s}{\lg r} < \frac{m}{n} + \frac{1}{n}. \tag{7}$$

В силу доказанной монотонности функции $L(n)$ из (6) следует

$$L(r^m) \leqslant L(s^n) \leqslant L(r^{m+1})$$

и, следовательно, в силу (4) и (5)

$$mL(r) \leqslant nL(s) \leqslant (m+1) L(r),$$

откуда

$$\frac{m}{n} \leqslant \frac{L(s)}{L(r)} \leqslant \frac{m}{n} + \frac{1}{n}; \tag{8}$$

наконец, из (7) и (8) вытекает

$$\left| \frac{L(s)}{L(r)} - \frac{\lg s}{\lg r} \right| \leqslant \frac{1}{n}.$$

Так как левая часть этого неравенства от n не зависит, а в правой n может быть выбрано сколь угодно большим, то

$$\frac{L(s)}{\lg s}=\frac{L(r)}{\lg r}$$

и, значит, ввиду произвольности r и s

$$L(n)=\lambda \lg n,$$

где λ — постоянная. В силу доказанной монотонности функции $L(n)$ мы имеем $\lambda \geqslant 0$, и наше утверждение доказано.

Это утверждение составляет собой частный случай $p_k=\frac{1}{n}$ $(1 \leqslant k \leqslant n)$ доказываемой теоремы. Рассмотрим теперь более общий случай, когда p_k $(k=1, 2, \ldots, n)$ любые рациональные числа. Пусть

$$p_k=\frac{g_k}{g} \quad (k=1, 2, \ldots, n),$$

где все g_k — натуральные числа, и $\sum\limits_{k=1}^{n} g_k=g$. Пусть конечная схема A состоит из n событий с вероятностями $p_1, p_2, \ldots, p_n$. Наша задача состоит в том, чтобы определить энтропию этой схемы. С этой целью мы рассмотрим вторую схему B, зависимую от A и определяемую следующим образом: схема B содержит g событий $B_1, B_2, \ldots, B_g$, которые мы разбиваем на n групп, содержащих соответственно $g_1, g_2, \ldots, g_n$ событий; если в схеме A наступило событие A_k, то в схеме B все события k-й группы (числом g_k) получают одну и ту же вероятность $\frac{1}{g_k}$, а все события других групп получают вероятность 0 (становятся невозможными).

Таким образом, при любом исходе A_k схемы A схема B обращается в систему g_k равновероятных событий, вследствие чего условная энтропия

$$H_k(B)=H\left(\frac{1}{g_k}, \frac{1}{g_k}, \ldots, \frac{1}{g_k}\right)=L(g_k)=\lambda \lg g_k,$$

а значит,

$$H_A(B)=\sum_{k=1}^{n} p_k H_k(B)=\lambda \sum_{k=1}^{n} p_k \lg g_k=\lambda \sum_{k=1}^{n} p_k \lg p_k+\lambda \lg g. \tag{9}$$

Обратимся теперь к объединённой схеме AB, состоящей из событий $A_k B_l$ $(1 \leqslant k \leqslant n,\ 1 \leqslant l \leqslant g)$. Такое событие возможно лишь тогда, если B_l принадлежит k-й группе. Таким образом, число возможных событий $A_k B_l$ при данном k равно g_k; общее же число возможных событий схемы AB равно $\sum\limits_{k=1}^{n} g_k=g$. Вероятность каждого возможного события $A_k B_l$ равна, очевидно, $p_k \frac{1}{g_k}=\frac{1}{g}$, т. е. одна и та же для всех этих событий. Таким образом, схема AB состоит из g равновероятных между собой событий, а поэтому

$$H(AB)=L(g)=\lambda \lg g.$$

Пользуясь свойством 2° и соотношением (9), мы находим:

$$\lambda \lg g = H(A) + \lambda \sum_{k=1}^{n} p_k \lg p_k + \lambda \lg g,$$

откуда

$$H(A) = H(p_1, p_2, \ldots, p_n) = -\lambda \sum_{k=1}^{n} p_k \lg p_k. \tag{10}$$

Наконец, соотношение (10), доказанное нами для рациональных $p_1, p_2, \ldots, p_n$, в силу предположенной непрерывности функции $H(p_1, p_2, \ldots, p_n)$ должно оставаться верным и при любых значених этих аргументов. Таким образом, теорема 1 доказана полностью.

3. ЭНТРОПИЯ ЦЕПЕЙ МАРКОВА

Пусть мы имеем простую стационарную цепь Маркова с конечным числом состояний $A_1, A_2, \ldots, A_n$ и матрицей переходных вероятностей p_{ik} $(i, k = 1, 2, \ldots, n)$. Обозначим через P_k вероятность состояния A_k $(1 \leqslant k \leqslant n)$, так что, в частности,

$$\sum_{k=1}^{n} P_k p_{kl} = P_l \quad (l = 1, 2, \ldots, n). \tag{11}$$

Если система находится в состоянии A_i, то переходы её в различные состояния A_k $(k = 1, 2, \ldots, n)$ образуют конечную схему

$$\begin{pmatrix} A_1 & A_2 & \ldots & A_n \\ p_{i1} & p_{i2} & \ldots & p_{in} \end{pmatrix},$$

энтропия которой

$$H_i = -\sum_{k=1}^{n} p_{ik} \lg p_{ik}$$

зависит от i и может рассматриваться как *мера количества информации, получаемой нами при продвижении в цепи Маркова на один шаг, отправляясь от начального состояния* A_i. Осреднение этой величины по всем начальным состояниям, т. е. величина

$$H = \sum_{i=1}^{n} P_i H_i = -\sum_{i=1}^{n} \sum_{k=1}^{n} P_i p_{ik} \lg p_{ik}$$

должна поэтому рассматриваться как *мера среднего количества информации, получаемой при продвижении в данной цепи Маркова на один шаг.* Эта величина H, которую мы будем называть энтропией данной цепи очевидно, характеризует собой эту цепь в целом; разумеется, она однозначно определяется заданием вероятностей состояний P_i и переходных вероятностей p_{ik} $(1 \leqslant i \leqslant n, 1 \leqslant k \leqslant n)$.

Все эти понятия, определённые для продвижения на один шаг, легко и естественно могут быть обобщены для случая перехода на любое число r шагов. Если система находится в состоянии A_i, то можно легко вычислить вероятность того, что в ближайших r испытаниях мы последовательно найдём её в состояниях $A_{k_1}, A_{k_2}, \ldots, A_{k_r}$, где $k_1, k_2, \ldots, k_r$ — любые числа ряда $1, 2, \ldots, n$. Таким образом, судьба системы, находя-

щейся в состоянии A_i, на r ближайших испытаний описывается некоторой конечной схемой (из n^r событий), имеющей определённую энтропию, которую мы будем обозначать через $H_i^{(r)}$ и рассматривать как меру количества информации при продвижении в цепи на r шагов, отправляясь от состояния A_i; величина же

$$H^{(r)} = \sum_{i=1}^{n} P_i H_i^{(r)}$$

должна рассматриваться как *среднее количество информации, даваемое продвижением в данной цепи Маркова на r шагов*; мы будем называть её энтропией данной цепи на r шагов. Определённая нами выше одношаговая энтропия H может, очевидно, записываться и в виде $H^{(1)}$.

Понимание величины $H^{(r)}$ как среднего количества информации, получаемой при продвижении в данной цепи Маркова на r шагов, для своего разумного обоснования естественно требует, чтобы для любых натуральных чисел r и s мы имели

$$H^{(r+s)} = H^{(r)} + H^{(s)},$$

или, что то же, $H^{(r)} = rH^{(1)}$ для любого натурального числа r. Легко убедиться, что это действительно так. В самом деле, соотношение $H^{(r)} = rH^{(1)}$ тривиальным образом верно для $r = 1$. Пусть оно имеет место для некоторого $r \geqslant 1$; покажем, что в таком случае и $H^{(r+1)} = (r+1) H^{(1)}$.

Пусть система находится в состоянии A_i; конечная схема, описывающая собой судьбу системы в $r+1$ ближайших испытаниях, может тогда рассматриваться как объединение двух (взаимно зависимых) схем:

А) схема перехода к ближайшему испытанию с энтропией $H_i^{(1)}$ и

В) схема, описывающая судьбу системы в r последующих испытаниях; энтропия этой схемы равна $H_k^{(r)}$, если схема А имела своим исходом событие A_k.

Согласно общему соотношению

$$H(AB) = H(A) + H_A(B)$$

мы имеем:

$$H_i^{(r+1)} = H_i^{(1)} + \sum_{k=1}^{n} p_{ik} H_k^{(r)}$$

и, следовательно (учитывая соотношение (11)),

$$H^{(r+1)} = \sum_{i=1}^{n} P_i H_i^{(r+1)} = \sum_{i=1}^{n} P_i H_i^{(1)} + \sum_{k=1}^{n} H_k^{(r)} \sum_{i=1}^{n} P_i p_{ik} =$$

$$= H^{(1)} + \sum_{k=1}^{n} P_k H_k^{(r)} = H^{(1)} + H^{(r)} = (r+1) H^{(1)},$$

что и требовалось доказать.

Применение понятия энтропии марковской цепи в теории информации в большей части случаев базируется на двух фундаментальных теоремах, которые мы докажем в следующем параграфе.

4. ФУНДАМЕНТАЛЬНЫЕ ТЕОРЕМЫ

Допустим теперь, что рассматриваемая нами цепь Маркова подчиняется закону больших чисел, т. е. что в достаточно длинной серии из s последовательных испытаний относительное число $\frac{m_i}{s}$ наступлений состояния A_i с вероятностью, сколь угодно близкой к единице, будет как угодно мало отличаться от P_i; другими словами, как бы малы ни были $\varepsilon > 0$ и $\delta > 0$, при достаточно большом s

$$P\left\{\left|\frac{m_i}{s} - P_i\right| > \delta\right\} < \varepsilon^{1)}. \tag{12}$$

Будем для краткости называть такую цепь эргодической.

Всякий возможный результат серии из s последовательных испытаний данной цепи Маркова может быть записан в виде «цепочки»

$$A_{k_1},\ A_{k_2},\ \ldots,\ A_{k_s}, \tag{C}$$

где $k_1, k_2, \ldots, k_s$ — числа ряда $1, 2, \ldots, n$. Вероятность реализации цепочки (C) не зависит (ввиду стационарности цепи) от того места цепи, где начинается предпринятая серия испытаний, и, очевидно, равна

$$p(C) = P_{k_1} p_{k_1 k_2} p_{k_2 k_3} \ldots p_{k_{s-1} k_s}.$$

Пусть i и l — два произвольных числа ряда $1, 2, \ldots, n$ и пусть m_{il} означает число тех пар вида $k_r k_{r+1}$ $(1 \leqslant r < s)$, в которых $k_r = i$, $k_{r+1} = l$. Тогда, очевидно, вероятность цепочки (C) может быть записана в виде

$$p(C) = P_{k_1} \prod_{i=1}^{n} \prod_{l=1}^{n} (p_{il})^{m_{il}}. \tag{13}$$

Теорема 2. *Сколь бы малы ни были $\varepsilon > 0$ и $\eta > 0$, при достаточно большом s все цепочки вида (C) могут быть разбиты на две группы, обладающие следующими свойствами: 1) вероятность $p(C)$ любой цепочки первой группы удовлетворяет неравенству*

$$\left|\frac{\lg \frac{1}{p(C)}}{s} - H\right| < \eta \tag{14}$$

и 2) сумма вероятностей всех цепочек второй группы меньше чем ε.

Другими словами, все цепочки за исключением некоторой весьма маловероятной группы имеют вероятности, заключённые между $a^{-s(H+\eta)}$ и $a^{-s(H-\eta)}$, где a — принятое основание системы логарифмов. H означает здесь энтропию данной цепи на один шаг.

Доказательство. Мы условимся считать цепочку (C) принадлежащей первой группе, если она обладает следующими двумя свойствами: 1) она возможна, т. е. $p(C) > 0$, и 2) для любых i, l $(1 \leqslant i \leqslant n,\ 1 \leqslant l \leqslant n)$ имеет место неравенство

$$|m_{il} - sP_i p_{il}| < s\delta. \tag{15}$$

Все остальные цепочки мы отнесём ко второй группе. Покажем, что это

---

[1]) А. А. Марков показал, что для этого достаточно предположить данную цепь «транзитивной», т. е. допустить, что при достаточно большом числе шагов возможен переход из любого состояния в любое другое. В тех цепях, с которыми имеет дело теория информации, эта предпосылка, повидимому, всегда выполняется.

разделение при достаточно большом s удовлетворяет обоим требованиям теоремы 2, если $\delta > 0$ достаточно мало.

1) Пусть цепочка (C) — первой группы. Из (15) следует тогда

$$m_{il} = sP_i p_{il} + s\delta\theta_{il}, \quad |\theta_{il}| < 1, \quad 1 \leqslant i \leqslant n, \quad 1 \leqslant l \leqslant n.$$

Эти выражения чисел m_{il} мы внесём теперь в (13), причём мы должны ещё иметь в виду, что требование возможности данной цепочки необходимо влечёт за собой $m_{il} = 0$ при $p_{il} = 0$, вследствие чего в произведении (13) мы должны ограничиться множителями, для которых $p_{il} > 0$, что мы будем отмечать знаком $*$ при произведениях. Мы находим:

$$p(C) = P_{k_1} \prod_i \prod_l{}^* (p_{il})^{sP_i p_{il} + s\delta\theta_{il}},$$

$$\lg \frac{1}{p(C)} = -\lg P_{k_1} - s \sum_i \sum_l{}^* P_i p_{il} \lg p_{il} - s\delta \sum_i \sum_l{}^* \theta_{il} \lg p_{il} =$$

$$= -\lg P_{k_1} + sH - s\delta \sum_i \sum_l{}^* \theta_{il} \lg p_{il},$$

откуда

$$\left| \frac{\lg \frac{1}{p(C)}}{s} - H \right| < \frac{1}{s} \lg \frac{1}{P_{k_1}} + \delta \sum_i \sum_l{}^* \lg \frac{1}{p_{il}},$$

и значит, при достаточно большом s

$$\left| \frac{\lg \frac{1}{p(C)}}{s} - H \right| < \eta,$$

где $\eta > 0$ сколь угодно мало, если δ достаточно мало. Таким образом, первое требование теоремы 2 выполнено.

2) Переходя теперь к оценке суммы вероятностей всех цепочек второй группы, заметим прежде всего, что входящие в эту группу невозможные цепочки при этой оценке могут, конечно, не учитываться, так как вероятности их равны нулю. Мы должны поэтому оценить сумму вероятностей лишь таких цепочек, для которых, хотя бы при одной паре индексов i, l, нарушается неравенство (15); для этого же достаточно оценить величину

$$\sum_{i=1}^{n} \sum_{l=1}^{n} P\{|m_{il} - sP_i p_{il}| \geqslant s\delta\}.$$

Закрепим сначала индексы i и l. В силу (12) мы имеем при достаточно большом s

$$P\left\{|m_i - sP_i| < \frac{\delta}{2} s\right\} > 1 - \varepsilon.$$

Если неравенство $\{\ \}$ выполнено, и s достаточно велико, то и m_i сколь угодно велико, а потому по теореме Бернулли

$$P\left\{\left|\frac{m_{il}}{m_i} - p_{il}\right| < \frac{\delta}{2}\right\} > 1 - \varepsilon.$$

Следовательно, вероятность выполнения обоих неравенств

$$|m_i - sP_i| < \frac{\delta}{2} s \tag{16}$$

и

$$|m_{il} - m_i p_{il}| < \frac{\delta}{2} m_i \leqslant \frac{\delta}{2} s \tag{17}$$

превышает $(1-\varepsilon)^2 > 1-2\varepsilon$. Но из (16) следует

$$|p_{il} m_i - sP_i p_{il}| < p_{il} \frac{\delta}{2} s < \frac{\delta}{2} s,$$

а это вместе с (17) даёт

$$|m_{il} - sP_i p_{il}| < \delta s. \tag{18}$$

Таким образом, при любых i и l мы имеем, если s достаточно велико,

$$P\{|m_{il} - sP_i p_{il}| < \delta s\} > 1 - 2\varepsilon,$$

и значит,

$$P\{|m_{il} - sP_i p_{il}| > \delta s\} < 2\varepsilon.$$

Отсюда

$$\sum_{i=1}^{n} \sum_{l=1}^{n} P\{|m_{il} - sP_i p_{il}| > \delta s\} < 2n^2\varepsilon.$$

Так как правая часть этого неравенства сколь угодно мала вместе с ε, то сумма вероятностей всех цепочек второй группы может быть сделана сколь угодно малой при достаточно большом s, т. е. второе требование теоремы 2 также оказывается выполненным. Таким образом, теорема 2 доказана.

Заметим теперь, что число всех s-членных цепочек вида (C) равно n^s, и расположим эти цепочки в порядке убывающих вероятностей $p(C)$. Будем отбирать эти цепочки в том порядке, как мы их расположили, до тех пор, пока сумма вероятностей отобранных цепочек не превзойдёт некоторого заранее назначенного постоянного числа λ $(0 < \lambda < 1)$. Обозначим через $N_s(\lambda)$ число отобранных таким образом цепочек. Теорема 2 позволяет нам установить следующую важную оценку числа $N_s(\lambda)$.

Теорема 3. $\lim\limits_{s\to\infty} \frac{\lg N_s(\lambda)}{s} = H$.

В частности, указанный предел не зависит от числа λ, если только $0 < \lambda < 1$ и λ остаётся постоянным при возрастании s.

Доказательство. Условимся называть цепочку (C) стандартной, если её вероятность $p(C)$ удовлетворяет неравенству (14), где η — некоторое фиксированное, сколь угодно малое положительное число. В силу теоремы 2 сумма вероятностей всех нестандартных цепочек как угодно мала при достаточно большом s. Неравенство (14) равносильно неравенствам

$$a^{-s(H+\eta)} < p(C) < a^{-s(H-\eta)}, \tag{19}$$

которые, следовательно, являются характеристическими для стандартных цепочек (a означает принятое нами основание системы логарифмов).

В число отобранных цепочек (с суммой вероятностей $> \lambda$) войдут:

1) все нестандартные цепочки с вероятностями $p(C) \geqslant a^{-s(H-\eta)}$; сумма вероятностей таких цепочек не превосходит суммы вероятностей *всех* нестандартных цепочек, которая при достаточно большом s становится в свою очередь меньше как угодно малого $\varepsilon > 0$;

2) некоторое число $M_s(\lambda)$ стандартных цепочек, сумма вероятностей которых должна быть больше чем $\lambda - \varepsilon$ (так как сумма вероятностей всех отобранных цепочек превосходит λ).

Нестандартные цепочки с вероятностями $p(C) \leqslant a^{-s(H+\eta)}$ в число отобранных войти не могут, так как согласно теореме 2 сумма вероятностей одних только стандартных цепочек уже превосходит λ. Таким образом, для всех отобранных цепочек $p(C) > a^{-s(H+\eta)}$, а потому сумма вероятностей отобранных цепочек больше чем $N_s(\lambda)\, a^{-s(H+\eta)}$; но, с другой стороны, эта сумма, очевидно, меньше чем $\lambda + q$, где q — вероятность последней из отобранных цепочек; таким образом,

$$N_s(\lambda)\, a^{-s(H+\eta)} < \lambda + q < \lambda + a^{-s(H-\eta)},$$

и значит (в силу $\lambda < 1$), при достаточно большом s

$$N_s(\lambda)\, a^{-s(H+\eta)} < 1,$$

откуда

$$\frac{\lg N_s(\lambda)}{s} < H + \eta. \tag{20}$$

Но, с другой стороны, отобранные нами $M_s(\lambda)$ стандартных цепочек имеют вероятности $p(C) < a^{-s(H-\eta)}$, в то время как сумма их вероятностей больше чем $\lambda - \varepsilon$. Отсюда

$$M_s(\lambda)\, a^{-s(H-\eta)} > \lambda - \varepsilon,$$

а потому и подавно

$$N_s(\lambda)\, a^{-s(H-\eta)} > \lambda - \varepsilon,$$

откуда

$$\frac{\lg N_s(\lambda)}{s} > H - \eta + \frac{1}{s} \lg(\lambda - \varepsilon). \tag{21}$$

Сопоставление неравенств (20) и (21), очевидно, доказывает теорему 3, так как число η мы можем считать при достаточно большом s сколь угодно малым.

То большое значение, которое получила теорема 3 для ряда приложений, обусловливается следующими соображениями. В то время как общее число цепочек типа (C) равно $n^s = a^{s \lg n}$, число $N_s(\lambda)$ отобранных цепочек равно, как показывает теорема 3, примерно a^{sH}. Если мы вспомним, что $\lg n$ есть максимальное значение энтропии H и что, следовательно, мы всегда (за исключением некоторого тривиального случая) имеем $H < \lg n$, и если мы выберем число λ чрезвычайно близким к единице, то теорема 3 показывает, что уже ничтожно малая доля общего числа цепочек (C) имеет (если s достаточно велико) сумму вероятностей, как угодно близкую к единице. Вместе с тем мы видим, что в вопросе о том, *как мала* эта доля, решающую роль получает *энтропия* данной марковской цепи.

5. ПРИЛОЖЕНИЕ К ТЕОРИИ КОДИРОВАНИЯ

Чтобы дать хотя бы один пример, иллюстрирующий схему практических применений понятия энтропии, мы рассмотрим теперь одну из простейших задач теории кодирования. Допустим, что подлежащий кодированию текст представляет собой последовательность символов (букв),

принадлежащих некоторой конечной группе (алфавит), и обозначим через m число имеющихся различных между собой символов (так что число различных между собой цепочек длины s равно m^s). Мы будем рассматривать этот текст как простую цепь Маркова употреблявшегося нами в двух предшествующих параграфах типа и предполагать известной его статистическую структуру, в частности его энтропию H, максимальное возможное значение которой есть, как мы знаем, $\lg m$. Мы ограничимся рассмотрением того простейшего случая, когда поступающий текст кодируется *в тот же алфавит*, т. е. каждая цепочка текста кодируется в некоторую цепочку символов того же алфавита (по существу, конечно, важно лишь то, что кодированный текст располагает тем же *числом* символов, как поступающий, обозначение же их никакой роли не играет). Само собой разумеется, что правила кодирования должны гарантировать однозначность восстановления первоначального текста по закодированному, для чего, в частности, различные цепочки поступающего текста обязательно должны кодироваться различно.

Непосредственно ясно, что, кодируя возможно более кратко наиболее часто встречающиеся цепочки и, напротив, оставляя более длинную кодировку для цепочек, встречающихся более редко, мы имеем возможность некоторого сокращения кодированного текста сравнительно с первоначальным, что, очевидно, может представлять деловую и экономическую выгоду.

Чтобы разобраться в имеющихся здесь возможностях, надо прежде всего выбрать те величины, которые могут естественным образом измерять собой такого рода сокращение посредством кодирования. Непосредственно ясно только, что как возможные размеры сжатия, так и выбор оптимального для этой цели кода целиком зависят от статистической структуры поступающего текста.

Каждая s-членная цепочка (C) символов входящего текста имеет определённую вероятность $p(C)$ и определённую длину $\sigma(C)$ цепочки кодированного текста, в которую она переходит после кодирования. Отношение $\sigma(C)/s$ может рассматриваться как «коэффициент сжатия» для данной s-членной цепочки (C). Математическое ожидание этого отношения

$$\mu_s = \frac{\sum\limits_C p(C)\,\sigma(C)}{s}$$

(где суммирование ведётся по всем цепочкам длины s) есть «среднее сжатие» для цепочек длины s; наконец, величина

$$\mu = \overline{\lim_{s\to\infty}}\,\mu_s,$$

которую мы будем называть коэффициентом сжатия (данного текста при данном коде), очевидно, и может естественным образом измерять собой сокращение данного входящего текста при данном способе кодирования.

Добавим, что во всех реально встречающихся случаях величина μ_s стремится при $s \to \infty$ к определённому пределу.

Нас интересует вопрос о том, каково при данной статистической структуре текста наименьшее значение коэффициента сжатия, которого можно достигнуть с помощью надлежащего кода. Попутно, разумеется, мы будем интересоваться и тем, как может быть установлен такой «оптимальный» код. На эти вопросы в основном полностью отвечает следующая замечательная простотой своей формулировки

Теорема 4. *Если энтропия поступающего текста равна H, то нижняя грань коэффициента сжатия μ по всем возможным кодам равна $H/\lg m$, где m — число различных между собой символов текста.*

Таким образом, для установления нижней грани возможного сокращения текста посредством кодирования нет надобности знать в деталях его статистическую структуру, а достаточно учитывать лишь его энтропию и число различных входящих в него символов. Так как $\lg m$ есть максимальное значение H при данном числе символов, то величину $H/\lg m$ иногда называют «относительной энтропией» данного текста.

Доказательство. Нам надо доказать, что 1] при любом коде $\mu \geqslant \frac{H}{\lg m}$ и 2] как бы мало ни было $\eta > 0$, существует код, для которого $\mu < \frac{H+\eta}{\lg m}$.

1] Пусть мы выбрали произвольный код и пусть $H' = H - 2\eta$, где $\eta > 0$ произвольно мало. Условимся называть s-членную цепочку (C) поступающего текста особой, если $\sigma(C) < H's/\lg m$. Так как число различных между собой k-членных цепочек кодированного текста равно m^k, то число всех особых s-членных цепочек поступающего текста не больше чем

$$m + m^2 + \ldots + m^{\left[\frac{H'\sigma}{\lg m}\right]} \leqslant m^{\frac{H's}{\lg m}} \left\{1 + \frac{1}{m} + \frac{1}{m^2} + \ldots\right\} = \frac{m}{m-1} a^{sH'},$$

где a — основание принятой системы логарифмов. Обозначим сумму вероятностей всех особых цепочек через λ_s и покажем, что $\lambda_s \to 0$ при $s \to \infty$.

В самом деле, пусть $\varepsilon > 0$ сколь угодно малое постоянное число; тогда в силу теоремы 3, чтобы получить сумму вероятностей, равную ε, надо взять

$$N_s(\varepsilon) > a^{s(H-\eta)} = a^{s(H'+\eta)}$$

наиболее вероятных цепочек; но при достаточно большом s число всех особых s-членных цепочек, как мы видели, не превосходит

$$\frac{m}{m-1} a^{sH'} < a^{s(H'+\eta)};$$

поэтому сумма λ_s их вероятностей меньше чем ε, если s достаточно велико, т. е. $\lambda_s \to 0$ при $s \to \infty$, что и требовалось доказать.

Так как для всякой неособой цепочки (C)

$$\sigma(C) \geqslant \frac{H's}{\lg m},$$

то математическое ожидание $\sigma(C)$ превосходит $(1-\lambda_s)\frac{H's}{\lg m}$ и, следовательно,

$$\mu_s \geqslant (1-\lambda_s)\frac{H'}{\lg m};$$

а так как $\lambda_s \to 0$ при $s \to \infty$, то

$$\mu = \overline{\lim_{s\to\infty}}\,\mu_s \geqslant \frac{H'}{\lg m} = \frac{H-2\eta}{\lg m};$$

наконец, так как η произвольно мало, то

$$\mu \geqslant \frac{H}{\lg m},$$

чем доказано первое утверждение теоремы 4.

2] Пусть $\eta > 0$ сколь угодно мало; для доказательства второго утверждения теоремы 4 мы прямо определим код, для которого $\mu < \frac{H+\eta}{\lg m}$. Пусть $\delta > 0$ произвольно мало. Число различных цепочек длины $\frac{s(H+\delta)}{\lg m}$ равно

$$m^{\frac{s(H+\delta)}{\lg m}} = a^{s(H+\delta)}.$$

Пусть, далее, и $\varepsilon > 0$ произвольно мало; в силу теоремы 3 число $N_s(1-\varepsilon)$ наиболее вероятных s-членных цепочек, в сумме дающих вероятность, большую или равную $1-\varepsilon$, меньше чем $a^{s(H+\delta)}$, если s достаточно велико; поэтому все эти «высоковероятные», s-членные цепочки могут быть закодированы с помощью цепочек длины $\frac{s(H+\delta)}{\lg m}$, которых, как мы видим, для этой цели достаточно. Что же касается оставшихся «маловероятных» s-членных цепочек (суммарной вероятности, меньшей ε), то каждую из них мы просто закодируем в саму себя. Чтобы гарантировать однозначность декодирования, достаточно, например, в кодированном тексте перед каждой такой s-членной цепочкой помещать какую-нибудь (всегда одну и ту же!) из неиспользованных в предыдущем цепочек длины $\frac{s(H+\delta)}{\lg m}$. При выбранном таким образом коде длина $\sigma(C)$ кодированной s-членной цепочки будет либо $\frac{s(H+\delta)}{\lg m}$, либо $s+\frac{s(H+\delta)}{\lg m}$, причём первое имеет место с вероятностью, меньшей или равной единице, а второе — с вероятностью, меньшей или равной ε; поэтому математическое ожидание $\sigma(C)$ не превосходит

$$\frac{s(H+\delta)}{\lg m} + \varepsilon\left[s+\frac{s(H+\delta)}{\lg m}\right] = s\left[\frac{H+\delta}{\lg m}(1+\varepsilon)+\varepsilon\right] < s\frac{H+\eta}{\lg m},$$

если ε и δ выбраны достаточно малыми.

Пусть мы теперь имеем большой текст (C) длины $S = ks$, где k очень велико. Этот текст может быть разбит на k цепочек $C_1, C_2, \ldots, C_k$ длины s; соответственно и кодированный текст длины $\sigma(C)$ распадается на k цепочек, длины которых соответственно равны $\sigma(C_1), \sigma(C_2), \ldots, \sigma(C_k)$, так что

$$\sigma(C) = \sigma(C_1) + \sigma(C_2) + \ldots + \sigma(C_k).$$

Математическое ожидание $\sigma(C)$ равно поэтому k-кратному математическому ожиданию величины $\sigma(C_1)$ и потому в силу предыдущего не превосходит

$$ks\left(\frac{H+\eta}{\lg m}\right)=S\frac{H+\eta}{\lg m}.$$

Отсюда

$$\mu s \leqslant \frac{H+\eta}{\lg m},$$

а следовательно, и

$$\mu \leqslant \frac{H+\eta}{\lg m};$$

этим доказано и второе утверждение теоремы 4.

ЛИТЕРАТУРА

[1] C. E. Shannon, A mathematical theory of communication, Bell Syst. Techn. Journ. **27** (1948), 379—423 и 623—656.
[2] C. E. Shannon, Some topies in information theory, Congress of Math. Cambridg. 1950.
[3] C. E. Shannon, General treatment of the problems of coding, Proc. Symp. London **102** (1950).
[4] R. M. Fano, The transmission of information, M. I. T. Tech. Rep. **65** (1949); 149 (1950).
[5] R. Fortet, Processus stationnaires et de Markoff et entropie, La Cybernetique, Paris, 1951, 9.